Monitoria modelos VAR

Teoría y aplicaciones en R de los modelos VAR

UNIVERSIDAD NACIONAL DE COLOMBIA

Monitores econometría II [1]

10 de diciembre de 2021

[1]Facultad de ciencias económicas
Monitoria Econonometría II

Table of contents

Introducción

Ideas generales de los modelos VAR

- Su planteamiento moderno provino de Christopher Sims (1980)
- VAR: Vector Autoregressive
- Principal herramienta econométrica que usan los Bancos Centrales para realizar sus análisis econométricos
- Punto de partida para modelos más sofisticados de empleando series de tiempo multivariadas
- Existe una estrecha relación entre los modelos *VAR* y los *DSGE*

Teoría modelos VAR

¿Por qué se utiliza un modelo VAR?

- El interés principal, se centra en encontrar las relaciones dinámicas entre las variables que conforman el VAR.
- Para encontrar dichas relaciones dinámicas se pueden emplean diferentes herramientas asociados al modelamiento VAR: como lo son las *IRF*, el *FEVD* y la *Causalidad de Granger*

Extensiones del modelo VAR

- **B-VAR**: Bayesian VAR
- **FAVAR**: Factor augmented VAR
- **S-VAR**: Structural VAR
- **P-VAR**: Panel VAR
- **TAR**: Threshold Autoregression. Modelo no lineal
- **VAR-X**: VAR que permite incluir regresores exógenos en el modelo VAR
- **VAR-GARCH**: VAR con errores modelados por heterocedasticidad condicional. Generalmente la parte del GARCH, se modela con un GARCH multivariado
- **Representación estado-espacio**: Permite representar cualquier modelo de series de tiempo que ven en el curso y mucho más. Se estiman por **filtro de Kalman**

S-VAR: Structural VAR

- En la práctica uno modela una situación económica utilizando generalmente S-VAR. La idea, es incluir información económicamente relevante dentro del modelo y encontrar relaciones dinámicas de interés en las variables.
- No obstante, un S-VAR no se puede estimar directamente. Primero, hay que estimar un VAR en forma reducida y luego mediante restricciones en las matrices de coeficientes del modelo S-VAR y de la matriz de varianzas y covarianzas del S-VAR se identifica el modelo S-VAR

Relación entre un VAR y un S-VAR

Un **VAR(p)** se representa como:

$$y_t = A_0 + A_1 y_{t-1} + \cdots + A_p y_{t-p} + e_t \tag{1}$$

Un **S-VAR(p)** se representa como:

$$By_t = A_0 + A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t \tag{2}$$

Para identicar el **S-VAR** se pone restricciones sobre la matriz **B** y la matriz de varianzas y covarianzas de ε.

Existen diferentes métodos de identificación de un **S-VAR**, es decir diferentes restricciones sobre las matrices B y $varcov(\varepsilon)$

Formas de identificar un VAR Estructural

Existen diferentes formas de identificar un S-VAR. Algunos de los métodos de identificación son controversiales.

- **Descomposición de Cholesky**: No incluye mucha teoría económica para la identificación. El orden de las variables importa. Planteamiento inicial de Sims en su artículo original.
- **Identificación utilizando teoría económica**: Se restringen los coeficientes dependiendo de lo que le digo la teoría
- **Descomposición Blanchard-Quah**: Aplicación netamente económica
- **Identificación por heterocedasticidad condicional**
- **Identificación por restricciones de signo**

VAR Estacionario

- Un **VAR estacionario** es un VAR donde todas las *raíces* de su polinomio característico están por fuera del *círculo unitario*. En R ésto se verifica con el comando **roots()**.
- Un *VAR estacionario* puede ser representado como un $VMA(\infty)$ **(Vector Moving Average)**.
- La representación $VMA(\infty)$ permite entre otras cosas calcular las *IRF* y la *FEVD* del *modelo VAR*. Si el VAR no se puede representar como un $VMA(\infty)$, entonces no se pueden calcular las IRF.

Funciones Impulso Respuesta (IRF)

- Permite hacer *inferencia causal*. Es decir, ver el **impacto causal** de un choque exógeno en una variable del sistema sobre el comportamiento dinámico de otra variable del sistema.
- No obstante, por la *correlación contemporánea* de los residuales del modelo VAR (aunque sean individualmente *ruido blanco* puede que estén correlacionadas contemporaneamente) por lo que las irf no describan el choque aislado de una variable sobre otra sino un choque correlacionado.(Se viola *Ceteris Paribus*)
- El comando **Phi** de vars permite calcular las matrizes de la representación $VMA(\infty)$ de donde salen las IRF.

IRF ortogonales y Descomposición de Cholesky

- La **descomposición de Cholestky** permite descomponer una matriz como un producto de una *matriz triangular inferior* por una *matriz triangular superior*.
- Al aplicar la **descomposición de Cholestky** a la **matriz de varianzas y covarianzas** del VAR estimado se permite encontrar errores no correlacionados (Por eso es que se emplea). Esto permite, encontrar IRF que si tienen **interpretación causal** dado que podemos aislar el efecto de una variable sobre la otra e interpretarlo de una única manera el impacto. A las IRF que resultan de aplicar el procedimiento anterior se les conoce como *IRF ortogonales*

IRF ortogonales y Descomposición de Cholesky

- El ordenamiento de las variables importa: la primera variable afecta contemporáneamente a todas las variables del sistema, mientras la segunda variable afecta contemporáneamente a todas las variables menos a la primera, la tercera afecta a todas menos a la primera y la segunda variable,etc...
- De igual forma, en el *contexto de S-VAR* la descomposición de Cholesky es uno de los principales métodos de identificación de un S-VAR.
- El comando **Psi** de vars permite calcular las matrices de la representación **VMA** bajo una estrategia de identificación ortogonal. Es decir, son los coeficientes de las IRF ortogonales n pasos adelante

Descomposición de varianza del error de pronóstico

- La **Descomposición de varianza del error de pronóstico** nos dice que proporción del movimiento de una variable en el futuro se debe a sus propios shocks versus a shocks de otras variables
- ¿Qué proporción de la varianza del error de pronóstico de y_1 es explicada por y_1 y y_2? ¿Qué proporción de la varianza del error de pronóstico de y_2 es explicada por y_1 y y_2?

Modelos VAR en R

Principales paquetes en R para trabajar VAR

Existen diferentes paquetes que permiten hacer hoy en día realizar modelación con **series multivaridas** en R:

- **vars**: *Paquete de referencia* que todo macroeconometrista que use R debe saber. Paquete se va a usar.
- **tsDyn**: "Sofisticación"del paquete *vars*. Tiene más funcionalidades y es más moderno
- **MTS**: Paquete que permite estimar varios tipos de modelos para series multivariadas entre ellos un B-VAR, un BEKK (garch multivariado), entre otros modelos

Metodología Box-Jenkins en el paquete vars

1. **Identificación del modelo**: *VARselect*
2. **Selección del modelo**: *VAR*
3. **Validación de supuestos**:
   - **serial.test**: Prueba de correlación serial (**Portmanteau Test**)
   - **arch.test**: Prueba de heterocedasticidad (**Arch multivariada**)
   - **normality.test**: Prueba de normalidad (**Jarque Bera Multivariado**)
4. **Uso del modelo**:
   - **Predict**: Pronósticos puntuales
   - **fanchart**: Regiones de probabilidad para el pronóstico
   - **irf**: Para calcular una IRF (comando del paquete *vars*).
   - **fevd**: Descomposición de varianza del error de pronóstico

Funciones principales del paquete vars

Table 2.9. Overview of package **vars**

function or method	class	methods for class	functions for class
VAR	varest	coef, fevd, fitted, irf, logLik, Phi, plot, predict, print, Psi, resid, summary	Acoef, arch.test, Bcoef, BQ, causality, normality.test, restrict, roots, serial.test, stability
SVAR	svarest	fevd, irf, logLik, Phi, print, summary	
SVEC	svecest	fevd, irf, logLik, Phi, print, summary	
vec2var	vec2var	fevd, fitted, irf, logLik, Phi, predict, print, Psi, resid	arch.test, normality.test, serial.test
fevd	varfevd	plot, print	
irf	varirf	plot, print	
predict	varprd	plot, print	fanchart
summary	varsum, svarsum, svecsum	print	
arch.test	varcheck	plot, print	
normality.test	varcheck	plot, print	
serial.test	varcheck	plot, print	
stability	varstabil	plot, print	

Ejemplo práctico

Simulación de un modelo VAR(1) en dos variables

Asumimos que conocemos el verdadero PGD, aunque en la vida real esto no es posible.

Esquemáticamente, se estima un VAR en forma reducida sin intercepto:

$$y_t = A_1 y_{t-1} + e_t \tag{3}$$

Matricialmente, el *modelo VAR* se ve así:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} 0{,}3 & 0{,}2 \\ 0{,}5 & 0{,}6 \end{pmatrix} + \begin{pmatrix} e_{1t} \\ e_{2t} \end{pmatrix} \tag{4}$$