

Ejemplo de simulación de Monte Carlo

Monitoria econometría II

25 de noviembre de 2021

1. Simulación de Monte Carlo lanzamiento de dos dados

1.1. Desarrollo conceptual/teórico

A continuación, se busca explicar al estudiante como realizar una *simulación de Monte Carlo* basandose en un ejemplo del texto *Applied time series econometrics* de Enders
El ejercicio del texto dice¹:

Example of the Monte Carlo Method

Suppose you did not know the probability distribution for the sum of the roll of two dice. One way to calculate the probability distribution would be to buy a pair of dice and roll them several thousand times. If the dice were fair, you would find that a sum on your rolls would approximate this result:

Sum	2	3	4	5	6	7	8	9	10	11	12
Percentage	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

Instead of actually rolling the dice, you can easily replicate the experiment on a computer. You could draw a random number from a uniform $[0, 1]$ distribution to replicate the roll of the first die. If the computer-generated number falls within the interval $[0, 1/6]$, set the variable $r_1 = 1$. Similarly, if the number falls within the interval $[1/6, 2/6]$, set $r_1 = 2$, and so on. In this way, r_1 will be some integer 1 through 6, each with a probability $1/6$. Next, draw a second number from the same uniform $[0, 1]$ distribution to represent the roll of die 2 (r_2). You complete your first Monte Carlo replication by computing the sum $r_1 + r_2$. If you compute several thousand such sums, the sample distribution of the sums will approximate the true distribution.

Of course, more complicated experiments are possible. It is interesting to note that this method was used to reform a standard recommendation at the blackjack tables. At one time, the recommendation was to “stick” if the dealer shows a 2 or a 3 and you hold a 12. Monte Carlo experiments of a game of blackjack showed that this recommendation was incorrect. Now, a sharp blackjack player will take another card in these circumstances.

Figura 1: Ejercicio de simulación de Monte Carlo de Enders

De la figura 1 se observa que claramente lo que se quiere es simular la distribución de la suma del lanzamiento de dos dados justos. Como los valores que puede tomar el dado 1 van entre 1 a 6 y los valores que puede tomar el dado 2 van entre 1 a 6, los valores de la suma del

¹Los interesados pueden revisar la sección 4.4 del libro (Enders, 2008). En específico el ejemplo se encuentra en la página 204 del texto.

lanzamiento de los dos dados deberían estar entre 2 a 12. El ejercicio lo que busca, es conocer la probabilidad de cada posible resultado que resulte de la suma de los dos dados lanzados, por ejemplo, encontrar cuál es la probabilidad de obtener que la suma de los dos dados lanzados sea un 3 o un 5.

La manera más fácil de modelar la situación anterior, es asumir que los resultados del lanzamiento del dado 1 es una variables aleatoria discreta X_1 que puede tomar los valores de 1 a 6 mientras que los resultados del lanzamiento del dado 2 es una variable aleatoria discreta X_2 que puede tomar los valores de 1 a 6. Por tanto, se busca encontrar la distribución de la variable aleatoria $X = X_1 + X_2$.

Encontrar esa distribución es muy sencilla, dado que se limita a un problema de contar² las posibles veces de que un resultado de la suma de los dos dados se obtenga sobre el total de posibles resultados. La tabla siguiente muestra la suma que se obtiene por cada valor posible de los dos lanzamiento de los dados:

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

El resultado 2 aparece una sola vez en la tabla anterior por lo que su probabilidad de ocurrir es $\frac{1}{36}$ mientras que el número 3 aparece dos veces por lo que su probabilidad de ocurrir es $\frac{2}{36}$ y así sucesivamente con cada número que aparece en la tabla hasta llegar al número 12.

Luego de encontrar dicha probabilidad teóricamente, cuyos valores son los que aparecen en la figura 1, se procede a resolver el problema computacionalmente utilizando *simulación de Monte Carlo*.

1.2. Desarrollo computacional por simulación de Monte Carlo

La simulación de Monte Carlo es un procedimiento muy habitual para encontrar numéricamente resultados probabilísticos que muy difícilmente se podrían calcular analíticamente.

En una simulación de Monte carlo lo que busca es replicar un proceso generador de datos por computadora. Para ser más específicos, se simula los datos con las características de la muestra en cuestión (Enders, 2008).

La simulación de Monte Carlo³ requiere los siguientes pasos Enders (2008):

1. Una simulación genera una muestra aleatoria de tamaño T y los parámetros o estadísticos de interés son calculados.
2. El anterior procedimiento se repite N veces (donde N es un número grande) de tal forma que la distribución del parámetro de interés o el estadístico muestral de interés pueda ser tabulada. Esta distribución simulada empíricamente es usada como un estimativo de la distribución teórica.

Finalmente, se resalta que en una simulación de Monte Carlo, la simulación se basa en una distribución teórica conocida, por ejemplo una distribución normal. Es decir, se necesita

²Es un problema de conteo porque el espacio de probabilidad en el que se define la variable aleatoria X es finito

³A veces en la literatura se le dice experimento de Monte Carlo

especificar una distribución teórica, a la hora de efectuar el procedimiento de simulación por Monte Carlo⁴.

Lo interesante de este procedimiento es que por métodos computacionales podemos obtener exactamente los mismos resultados que obtuvimos en el desarrollo analítico anterior. Si bien, este ejemplo es muy sencillo y solo ilustrativo, como ya se mencionó anteriormente, hay procesos aleatorios y distribuciones probabilísticas tan complejas, como es el caso cuando se trabaja por ejemplo en econometría bayesiana, que es necesario utilizar métodos de simulación para conocer la distribución de interés⁵.

Ahor bien, respecto a lo que nos concierne a nosotros, vamos a utilizar la simulación de Monte Carlo, para conocer las probabilidades de que ocurra un resultado en particular asociado a la suma del lanzamiento de los dos dados justos. En términos generales el script consiste en una función general que me realiza la simulación del lanzamiento de los dos dados, calcula la suma del resultado de dichos lanzamientos para cada dado y realiza la simulación de que dichos lanzamientos se realizan 100000 veces. Es decir, en una sola función se simula el lanzamiento de dos dados (y se calcula la suma de los lanzamientos) 100.000 veces. Posteriormente, se genera un histograma que recopila gráficamente los resultados de la simulación y que muestra claramente que los resultados obtenidos analíticamente son iguales a los obtenidos por la simulación⁶

El procedimiento a seguir es el siguiente⁷:

1. Se construye la función que me simula un número muy grande de veces el lanzamiento de dos dados y calcula la suma que resulte del lanzamiento de los dos dados⁸.
 - a) Se simula el lanzamiento de un dado. Para ello se utiliza un if condicional que me permite construir un dado justo. Como es un dado justo, cualquier de las 6 caras debería tener la misma probabilidad de salir y el condicional lo que busca es que se permite obtener con la misma probabilidad cualquier de las 6 caras del dado. Lo que me garantiza que sea un dado justo, es que a la hora de seleccionar la cara del dado, se parte de que dicha cara del dado se obtiene una distribución uniforme discreta que va de 1 a 6 y que tiene la misma probabilidad para cada número entero que está entre 1 y 6⁹.
 - b) Luego de simular, como sería el lanzamiento de un solo dado, se genera una estructura de control ciclica, en este caso un for, de tal forma que pueda realizar el lanzamiento de los dados muchas veces, en realidad, lo que se hace es que en cada iteración del for se lanzan dos dados, y eso se realiza 100000 veces.

⁴Esto en contraste por una simulación por *bootstrapping* donde la simulación se base en un remuestreo con reemplazo de la misma muestra que es este estudiando y por tanto no se basa en suponer una distribución teórica como si ocurre en la simulación por Monte Carlo. La simulación por bootstrapping es habitual emplearla a la hora de hacer inferencia estadística y encontrar intervalos de confianza sobre muestras que no distribuyen normal

⁵Para los interesados, para conocer muchas de las distribuciones que se emplean a la hora de hacer estimaciones en econometría bayesiana es necesario hacer una sofisticación del procedimiento visto acá que se conoce como simulación de Monte Carlo por Cadenas de Markov: Markov Chain Monte Carlo (MCMC)

⁶Recuerde que un histograma, entre otras cosas, me permite conocer la distribución de probabilidad de una variable aleatorio discreta, que es el uso que se le da en éste ejercicio.

⁷Al final del documento, se encuentra el código en R empleado para que puedan reproducir el presente ejemplo del lanzamiento de los dos dados.

⁸En el script se simula 100.000 veces pero eso es un parámetro que se puede ajustar por diseño de la función de tal forma que se pueden efectuar más o menos simulaciones. Se recomienda un mínimo de 10.000 simulaciones para que los resultados computacionales se empiecen a acercar a los resultados teóricos.

⁹En realidad, lo que se hace en el código es un poco más complejo. Se parte de una distribución uniforme continua que va de 0 a 1 y se genera un número de esa distribución. Como dicho número está entre 0 y 1, lo que se hace es partir el intervalo $[0, 1]$ en 6 partes iguales y ver en que parte del intervalo cae el número generado por la distribución uniforme continua. Sabiendo en que parte cayó es posible asignarle un número entero asociado a dicho grupo. Por ejemplo, si el valor que produce la distribución uniforme continua es 0.987434 ese número pertenece al grupo 6 de la partición del intervalo $[0, 1]$ y por ende se le asocia el número asociado al último grupo de dicha partición, a saber 6

- c) Se almacenan en un dataframe los resultados de la simulación.
2. Se ejecuta la función descrita anterior de tal forma que se genera una muestra que resultad de la simulación de monte carlo. Se especifica un número de repeticiones de 100000 pero en la práctica podrían hacerse más o menos repeticiones, ajustando el parámetro de la función, dependiendo de las necesidades del investigador¹⁰.
 3. Se gráfica la distribución de probabilidad asociado a la suma del lanzamiento de los dos dados utilizando el dataframe generado en la ejecución de la simulación. La razón de utilizar un histograma es que es un forma gráfica de visualizar la distribución de probabilidad de una variable aleatoria discreta, en este caso la suma del resultado del lanzamiento de dos dados.

La imagen 2 muestra la distribución de probabilidad asociada a la suma que resulte del lanzamiento de dos dados justos. Las probabilidades que me muestra esta simulación, son exactamente iguales a la probabilides teóricas que se encuentran descritas en la figura 1. Por ejemplo, se ve que en 7 se obtiene un probabilidad de 0.1666667 aproximadamente y se sabe que teóricamente la probabilidad de que la suma del lanzamiento de los dos dado sea 7 es $\frac{6}{36} = 0.166667$. Lo cual muestra que los dos resultados son iguales.




Figura 2: Histograma de los resultados de la simulación de Monte Carlo para el lanzamiento de los dos dados

En conclusión, se muestra el poder que tiene la simulación de Monte Carlo, dado que literalmente simulando mucha muchas veces el lanzamiento de dos dados justos¹¹ fue posible encontrar la distribución de probabilidad de la suma de dos dados justos y además, dicho resultado fue equivalente al cálculo teórico obtenido por un procedimiento analítico. Los resultados anteriores se pueden extender para procesos aleatorios más sofisticados y realiar simulaciones

¹⁰Se aconseja al lector que haga la simulación con un bajo número de repeticiones y luego vaya aumentando el número de repeticiones para ver como cambian los resultados

¹¹Obviamente, simulando computacional y no físicamente el lanzamiento de un dado, aunque si el lector lanzara físicamente los dos dados 100000 veces debería obtener el mismo histograma de la figura 2

es muy común a la hora de trabajar con series de tiempo. En particular, a la hora de trabajar con series no estacionarias es necesario emplear en el cálculo de algunos estadísticos métodos de simulación dado que los supuestos de regresión estándar dejan de aplicar, en particular el supuesto de normalidad. Este es el caso, por ejemplo, del estadístico de Dickey Fuller en el que no es posible calcular su función de densidad de manera analítica, y por ende la forma en la que Dickey y Fuller calcularon la distribución de probabilidad de dicho estadístico (y al mismo tiempo los intervalos de confianza que aparecen en los textos guía de series de tiempo y en los paquetes econométricos) fue precisamente a partir de una simulación de Monte Carlo como la que se ilustra en el presente ejemplo.

2. Código en R de la simulación de Monte Carlo para la suma del resultado del lanzamiento de dos dados justos

```
# Simulación de Monte Carlo Enders: suma de dos dados justos (ejemplo pag. 204) ----

# La idea es simular la probabilidad de obtener un determinado valor
# dado la suma de los resultados de dos dados justos

library(tidyverse)

# función que permite realizar la simulación de Monte Carlo
monte_carlo = function(rep){
  # set_number_dado simular el lanzamiento de un dado
  set_number_dado = function(random){
    number = 0
    if (random <= 1/6){
      number = 1
    }else if(1/6 < random & random <= 2/6){
      number = 2
    }else if(2/6 < random & random <= 3/6){
      number = 3
    }else if(3/6 < random & random <= 4/6){
      number = 4
    }else if(4/6 < random & random <= 5/6){
      number = 5
    }else{
      number = 6
    }
    return(number)
  }
  # vector que almacena los resultados de la simulación de monte carlo
  vect = c()
  # simula rep veces el lanzamiento de dos dados y sumo sus resultados
  for (number in 1:rep){
    # genero los dos lanzamientos de los dos dados
    random1 = set_number_dado(runif(1)) # la distribución que se escogió para hacer la simu
    random2 = set_number_dado(runif(1))
    vect = append(vect, random1 + random2)
  }
  df = as_tibble(vect) %>%
    mutate(value = as.factor(value))
}
```

```
    return(as_tibble(vect))
  }

# Se realiza la simulación de Monte Carlo
prueba = monte_carlo(100000)# se repite 100000 veces el lanzamiento de los dos dados para g

# Histograma que muestra que se alcanzan la distribución teórica propuesta por Enders
# en el ejemplo de la pag. 204
graph = prueba %>%
  ggplot(aes(x = value)) +
  geom_bar(aes(y = (..count..)/sum(..count..))) +
  ylab("Probabilidad suma de los dos dados") +
  theme_light(); graph

# El historgrama representa una distribución empírica igualita a la distribución teórica di.
```

Referencias

Enders, W. (2008). *Applied econometric time series*. John Wiley & Sons.